

Inference Service Provider?

El papel de los operadores en la distribución de la inferencia

Alfredo Giordano

Octubre de 2026



Modelos

Capacidad

Distribución

Aplicaciones

Empresas

¿Dónde encaja el ISP?

**La inferencia cuesta menos.
El gasto puede crecer.**

20%

Empresas de la UE que usan IA

2025, empresas con al menos 10 empleados
(Eurostat)

÷280

Coste de inferencia

Reducción superior a 280 veces a nivel GPT-3.5
Noviembre de 2022 – octubre de 2024 (Stanford)

20–30%


del opex de las telco

Agentes de IA y tokens en el escenario de Bain a 3–5 años
(Bain)

Proporción del gasto total.
No un aumento del opex del 20–30%.

Dentro de una solicitud

Un LLM como ejemplo. El perfil de trabajo determina los recursos.




Memoria del modelo + memoria de las solicitudes activas

Contexto, salida y concurrencia cambian el dimensionamiento.

¿Cerca de qué?


La entrada de la API, el lugar de ejecución y los datos pueden estar en ubicaciones distintas.



Carga	Factor que medir	Ubicación que comparar
Vídeo local	Volumen de datos que transferir	Sede del cliente / nodo cercano
Voz interactiva	Tiempo total de respuesta	Región / hub
Lotes documentales	Coste y tiempo de finalización	Hub / proximidad a los datos

La capacidad que queda tras un fallo

Ejemplo didáctico: dos nodos independientes, cada uno con 100 solicitudes/minuto.



100

solicitudes/minuto
con un nodo disponible

La capacidad de reserva se incluye en el precio.

Valores hipotéticos. Mismo modelo, perfil de solicitudes y objetivo de rendimiento. Capacidad residual en régimen estable, tras el failover.


2030: el nodo sigue a la demanda

Hipótesis: agrupar cargas compatibles hace sostenible la capacidad regional.

Empresas y firmas de software

ISP

Capacidad regional compartida



La relación con el cliente puede preceder a la capacidad propia.

¿Por qué función nos pagarán?

Tres posiciones posibles en la misma cadena de valor.



Papel del ISP	Qué compra el cliente	Ingresos posibles
Distribución	Acceso y asistencia	Margen mayorista
Prestación	Capacidad en las condiciones acordadas	Consumo / capacidad reservada
Gestión	Integración y gobierno del servicio	Cuota operativa

Las empresas de software integran el servicio en las aplicaciones.

La prueba previa a la inversión

Una prueba debe permitir decidir qué capacidad adquirir o instalar.

01

Aplicación real

Cliente y empresa de software definen un resultado útil.

02

Dos ubicaciones

Mismo modelo, mismas entradas y criterios de calidad.

03

Carga y fallo

Tiempos de respuesta, colas y recuperación bajo presión.

04

Margen completo

Incluye capacidad de reserva, operación y asistencia.

€/resultado

**¿Cuánto cuesta
una tarea bien hecha?**

¿Qué podría desmentirnos?



SaaS y dispositivos

¿Cuánta inferencia seguirá al alcance de los operadores?

Elección del cliente

¿Qué ventaja medible hará que nos elijan?

Capacidad compartida

¿Cómo de sustituibles serán modelos y proveedores?

**¿Por qué responsabilidad en la inferencia
estamos dispuestos a cobrar?**

Gracias

Gracias

Alfredo.Giordano@Warian.net



neanog